Seleção por momentum e ponderação por previsões GARCH no mercado acionário brasileiro

Gabriel Hansen
Trainee da FGV Quant
São Paulo, Brasil
gabriel.hansen2006@gmail.com

Júlio Turolla
Trainee da FGV Quant
São Paulo, Brasil
julioreisturolla@gmail.com

Theo Koga
Trainee da FGV Quant
São Paulo, Brasil
koga.y.theo@gmail.com

***Resumo*—Este trabalho desenvolve e avalia uma estratégia quantitativa para o mercado acionário brasileiro que separa a construção da carteira em duas camadas: (i) a seleção dos ativos, conduzida por um sinal de momentum de seção transversal, e (ii) o dimensionamento das posições, conduzido por previsões de volatilidade condicional obtidas por modelos da família GARCH. Em cada rebalanceamento mensal, as ações de um universo de 30 papéis da B3 são ordenadas pelo retorno acumulado entre doze meses e um mês antes da formação, e as mais bem classificadas recebem pesos iguais ou inversamente proporcionais ao risco previsto para o mês seguinte. A configuração é escolhida entre 150 alternativas no treino (2017 a 2020), conferida na validação (2021) e aplicada uma única vez no teste (2022 a 2025). No treino, o momentum supera o Ibovespa e a carteira igualmente ponderada do universo, e a configuração vencedora atinge Sharpe de 1,38 sobre o CDI. Fora da amostra o quadro se inverte: a configuração escolhida tem Sharpe de −0,43 no teste, a ordenação das 150 configurações entre treino e teste tem correlação de −0,53, e o momentum 12-1 Top 5, a especificação mais convencional, fica próximo do CDI. A ponderação por volatilidade reduz a volatilidade realizada em todos os períodos, mas reduz o Sharpe nas 135 combinações do treino, com diferença estatisticamente significativa para o GARCH(1,1). O mecanismo é econômico: no treino, os vencedores do momentum eram justamente os ativos de maior volatilidade prevista, e o inverso do risco retirava peso deles; no teste essa relação desaparece, e o custo da ponderação também.**

***Palavras-chave*—Momentum, volatilidade condicional, GARCH, dimensionamento de posições, backtest, mercado acionário brasileiro**

I. Introdução

Estratégias baseadas em retornos passados ocupam posição central em finanças quantitativas por uma razão simples: ativos que superaram seus pares nos últimos meses tendem a continuar superando no horizonte seguinte, padrão observado em diferentes mercados e períodos. Na sua forma de seção transversal, o momentum compara os ativos entre si em cada data e concentra a carteira nos vencedores relativos. O retorno médio elevado, no entanto, vem acompanhado de um risco que não é constante. As perdas mais severas dessas estratégias tendem a ocorrer em episódios de volatilidade alta, justamente quando a carteira está concentrada em ativos que acumularam ganhos rápidos e são mais sensíveis a reversões.

Essa característica sugere que a decisão de quais ativos comprar e a decisão de quanto alocar em cada um podem ser tratadas separadamente. A estratégia desenvolvida neste trabalho formaliza essa separação. O sinal de momentum define a composição da carteira, e uma previsão de volatilidade condicional define os pesos, de modo que ativos com risco esperado maior recebem participação menor. A escolha de um modelo condicional, e não de uma medida histórica fixa, decorre da própria dinâmica dos retornos: a volatilidade das ações se agrupa no tempo e é persistente, o que torna seu nível nas semanas seguintes parcialmente previsível a partir do comportamento recente. Há, contudo, uma tensão embutida na combinação. Os ativos selecionados pelo momentum costumam ser os de maior volatilidade recente, e ponderar pelo inverso do risco reduz a exposição exatamente a eles. O efeito líquido sobre a carteira é uma questão empírica, avaliada pelos indicadores de desempenho e risco em comparação com variantes de referência.

A aplicação ao mercado brasileiro é deliberada. Um universo restrito à B3 tem uma única moeda, um único calendário de negociação e uma única taxa livre de risco, o que elimina fontes de ruído alheias ao objeto do estudo. A combinação de mercados exigiria tratar risco cambial, que passaria a compor o resultado da carteira, e conciliar feriados não coincidentes, que distorcem retornos diários e correlações. Além disso, o CDI elevado em boa parte da amostra torna exigente a avaliação de qualquer estratégia acionária por excesso de retorno, e a disponibilidade de preços ajustados por proventos com cobertura adequada permite reconstruir a série de retornos totais com confiabilidade. Por outro lado, o mercado brasileiro impõe restrições que precisam ser explicitadas: histórico mais curto, universo de ativos líquidos reduzido e maior sensibilidade dos resultados a poucos episódios extremos.

Os resultados se organizam em três achados. Primeiro, o momentum gera desempenho expressivo dentro da amostra, mas a configuração escolhida pelo maior Sharpe no treino é das que mais se deterioram fora dela, e a ordenação das configurações praticamente se inverte entre treino e teste. Segundo, a ponderação por volatilidade cumpre o que promete em termos de risco, reduzindo a volatilidade realizada da carteira em todos os períodos, mas não melhora o retorno ajustado ao risco: no treino, piora o Sharpe em todas as combinações avaliadas. Terceiro, esse custo tem uma explicação econômica identificável, a correlação entre o sinal de momentum e a volatilidade prevista, cujo sinal muda ao longo da amostra.

A. Seleção e dimensionamento

Considere um universo de ativos indexados por i e datas de rebalanceamento t. Em cada data, a estratégia produz um conjunto de ativos selecionados S_t e um vetor de pesos w_t, mantidos até a data seguinte. O retorno diário da carteira entre rebalanceamentos é

$$r_p(d) = \sum_{i \in S_t} w_{i,d-1} \cdot r_{i,d}, \tag{1}$$

em que $r_{i,d}$ é o retorno simples do ativo i no dia d e os pesos $w_{i,d-1}$ evoluem com os retornos dos ativos desde a última execução. A separação em camadas tem duas implicações. A primeira é que cada camada pode ser avaliada isoladamente: mantida a mesma seleção S_t, a comparação entre pesos iguais e pesos baseados em volatilidade atribui as diferenças nos indicadores exclusivamente ao dimensionamento. A segunda é que as duas camadas operam em horizontes compatíveis. O sinal de momentum resume o desempenho relativo dos últimos meses, enquanto a previsão de volatilidade descreve o risco esperado durante o mês em que a posição ficará aberta.

II. Base de dados

A. Base e cobertura

A implementação parte de preços de fechamento diários, ajustados por proventos e em moeda original, extraídos da Economatica para 30 ações negociadas na B3, de janeiro de 2015 a outubro de 2026. O universo distribui-se entre setores distintos, como financeiro, materiais básicos, petróleo, utilidade pública, consumo e bens industriais, o que reduz o risco de que o sinal reflita a dinâmica de um único setor; a lista completa está no Apêndice A. O ajuste por proventos é necessário porque pagamentos de dividendos reduzem o preço de tela sem representar perda ao acionista; a série ajustada preserva o retorno total entre duas datas, que é a grandeza relevante para o backtest.

A composição do universo exige dois cuidados. O primeiro é a presença de duas classes de ações de um mesmo emissor em dois casos, Klabin (KLBN3 e KLBN11) e Santander (SANB3 e SANB11), cujos retornos são altamente correlacionados, de modo que o número de emissores distintos é 28. O segundo é mais sensível: a lista de ativos foi definida com base na relevância atual das empresas. Esse critério incorpora informação sobre sobrevivência que não estaria disponível no início da amostra, pois empresas que perderam relevância ou deixaram de ser negociadas ao longo do período não fazem parte do universo. É uma forma de *forward bias* na construção do universo investível, que tende a favorecer estratégias compradas e cuja magnitude é discutida na Seção VI.

B. Tratamento dos preços e retornos

Os dias sem cotação para nenhum ativo, correspondentes a feriados da B3, são removidos. Ausências pontuais de um único pregão em um ativo são preenchidas com o último preço disponível, procedimento que usa apenas informação passada; lacunas mais longas permanecem ausentes. Preços não positivos ou infinitos interrompem o processamento em vez de serem corrigidos silenciosamente. Os retornos diários simples são calculados entre observações válidas de cada ativo, e um ativo só participa do ranking de uma data se possuir os preços necessários para o cálculo do sinal. Por esse critério, ativos listados ao longo da amostra entram no universo apenas após acumularem histórico suficiente, como a CAML3, listada em setembro de 2017 e elegível a partir do final de 2018.

C. Taxa livre de risco e referências

A taxa livre de risco é o CDI diário, expresso como taxa ao dia e alinhado às datas de negociação. Até dezembro de 2021, utiliza-se a série 12 do Sistema Gerenciador de Séries Temporais do Banco Central. De 2022 em diante, a série é reconstruída a partir da taxa Selic efetiva de cada período de vigência das reuniões do Copom, também divulgada pelo Banco Central. A reconstrução foi validada no período em que as duas fontes se sobrepõem: entre 2019 e 2021, a série reconstruída coincide com a série oficial, com diferença diária máxima de $3,7 \times 10^{-7}$ e retornos anuais idênticos até a quinta casa decimal.

As estratégias são comparadas com quatro referências. A primeira é a carteira igualmente ponderada do universo, rebalanceada mensalmente nas mesmas datas, com os mesmos custos e composta pelos ativos com 21 retornos válidos consecutivos na data do sinal; ela isola o que o ranking de momentum acrescenta sobre simplesmente comprar todo o universo. A segunda é o Ibovespa, disponível até dezembro de 2025. A terceira reúne o IBrX 50, o índice Small Cap e o índice de Dividendos, disponíveis apenas até 2021 e por isso usados somente no treino e na validação. A quarta é o próprio CDI. Os índices são tratados como referências sem custo de replicação.

III. Estrutura metodológica

A. Sinal de momentum e seleção

Em cada data de formação t, correspondente ao último pregão de cada mês, o sinal do ativo i é o retorno acumulado entre L e 21 pregões antes de t:

$$M_{i,t} = \frac{P_{i,t-21}}{P_{i,t-L}} - 1, \quad L \in \{126, 189, 252\}. \tag{2}$$

A janela principal é a 12-1 ($L = 252$), e as alternativas 9-1 e 6-1 são avaliadas no treino. A exclusão do último mês não é meramente uma convenção: no curtíssimo prazo, retornos tendem a apresentar reversão, e incluir o mês mais recente misturaria ao sinal um componente de sentido oposto.

Os ativos elegíveis são ordenados de forma decrescente pelo sinal, e a carteira contém apenas posições compradas. São avaliadas duas famílias de regras. Na regra Top N, com $N \in \{5, 10, 15\}$, a carteira é formada pelos N primeiros ativos do ranking. Na regra de *deadband*, a carteira mantém cinco posições, mas um ativo já presente só é vendido se cair abaixo de uma posição limite, igual a 7 ou 10; as vagas abertas são preenchidas pelos ativos mais bem classificados ainda fora da carteira. O *deadband* reduz o *turnover* associado

a oscilações marginais no ranking, que em geral refletem ruído e não mudança efetiva de sinal.

B. Evidência de heterocedasticidade condicional

A camada de dimensionamento pressupõe que a variância dos retornos não seja constante e que dependa do seu próprio passado. Essa hipótese foi testada ativo a ativo, com log-retornos diários em pontos percentuais e a amostra completa. Os testes têm caráter diagnóstico: caracterizam o processo gerador dos retornos e não participam da escolha de parâmetros da estratégia.

O teste ARCH-LM rejeita a hipótese de variância constante, ao nível de 5%, em todos os 30 ativos com 1, 5 e 10 defasagens, e em 29 dos 30 com 20 defasagens. O teste de Ljung-Box aplicado aos retornos ao quadrado rejeita a ausência de autocorrelação em todos os ativos. A autocorrelação média dos retornos ao quadrado nas 20 primeiras defasagens é de 0,116, contra 0,022 em valor absoluto para os retornos, contraste que caracteriza o agrupamento de volatilidade: a direção do retorno é pouco previsível, mas sua magnitude é persistente. A distribuição dos retornos também se afasta da normal, com curtose em excesso mediana de 6,7. A análise em janelas móveis de três anos indica que o efeito não é produzido por poucos episódios extremos, já que, na mediana dos ativos, 71% das janelas rejeitam a variância constante.

C. Modelo de volatilidade

O modelo principal é um GARCH(1,1) com média zero e inovações t de Student padronizadas:

$$\begin{aligned} r_{i,t} &= \sigma_{i,t} \cdot z_{i,t}, \quad z_{i,t} \sim t(\nu), \\ \sigma^2_{i,t} &= \omega + \alpha \cdot r^2_{i,t-1} + \beta \cdot \sigma^2_{i,t-1}, \end{aligned} \tag{3}$$

em que $r_{i,t}$ é o log-retorno diário em pontos percentuais, α mede a reação da variância a choques recentes e β a persistência da variância passada. A opção por um GARCH(1,1), em vez de um ARCH de ordem elevada, decorre da memória longa identificada na seção anterior. A persistência $\alpha + \beta$ tem mediana de 0,984 entre os ativos, o que corresponde a uma meia-vida de cerca de 44 pregões para um choque de volatilidade, calculada como $\ln(0{,}5)/\ln(\alpha+\beta)$. Um ARCH só reproduziria esse padrão com dezenas de defasagens e, portanto, dezenas de parâmetros estimados em janelas de dois a quatro anos, com perda de estabilidade. No GARCH, o termo $\sigma^2_{i,t-1}$ resume todo o histórico de choques, e o mesmo comportamento é capturado com três parâmetros de variância. Os critérios de informação são consistentes com essa escolha: o BIC prefere o GARCH(1,1) à variância constante em todos os ativos e ao GJR em 23 dos 30, e os resíduos padronizados deixam de apresentar efeito ARCH em 24 dos 30 ativos após a estimação. A meia-vida superior a um mês tem também uma implicação prática: como a carteira é mantida por cerca de 21 pregões, a volatilidade observada na data do sinal ainda carrega informação sobre o período em que a posição estará aberta. A distribuição t acomoda as caudas pesadas dos retornos, e os graus de liberdade estimados têm mediana de 6,5, distante do caso normal.

Duas especificações alternativas compõem a comparação. A primeira é o GJR, que permite resposta assimétrica da variância a retornos negativos:

$$\begin{aligned} \sigma^2_{i,t} = \omega + \big(\alpha + \gamma \cdot \mathbb{1}\big[r_{i,t-1} < 0\big]\big) \cdot r^2_{i,t-1} \\ + \beta \cdot \sigma^2_{i,t-1}. \end{aligned} \tag{4}$$

O coeficiente γ é positivo em 26 dos 30 ativos, mas estatisticamente significativo em apenas 13, o que justifica tratar o GJR como alternativa e não como especificação principal. A segunda é o EWMA, uma média exponencial dos retornos ao quadrado que dispensa estimação, avaliada com fatores de decaimento $\lambda \in \{0{,}90; 0{,}94; 0{,}97\}$. O EWMA com $\lambda = 0{,}94$ serve ainda como previsão de reserva quando o otimizador do GARCH não converge, situação que não ocorreu em nenhuma das estimações realizadas.

D. Previsão da volatilidade

Em cada data de sinal, o modelo é reestimado para cada ativo usando somente os retornos observados até o fechamento daquela data, em uma janela móvel de w pregões, com $w \in \{504, 756, 1008\}$ e mínimo de 252 observações. A volatilidade usada na decisão é a média prevista para o horizonte de manutenção:

$$\hat{\sigma}_{i,t} = \left[\frac{1}{21} \sum_{h=1}^{21} E_t\big(\sigma^2_{i,t+h}\big) \right]^{\frac{1}{2}}. \tag{5}$$

Como a variância prevista converge gradualmente para seu nível de longo prazo à medida que o horizonte aumenta, a média sobre 21 pregões é mais adequada a uma carteira mensal do que a previsão de um único dia.

O início da amostra em janeiro de 2015 impõe uma restrição às janelas de estimação. As janelas de 756 e 1008 pregões só ficam completas a partir de 2018 e 2019, respectivamente; antes disso, a estimação utiliza todo o histórico disponível. Em todo o ano de 2017, as janelas de 756 e 1008 pregões produzem previsões idênticas, e a de 504 difere delas apenas marginalmente. A comparação entre janelas é, portanto, informativa sobretudo a partir de 2019.

E. Construção e ponderação da carteira

Os pesos dos ativos selecionados são proporcionais ao inverso da volatilidade prevista:

$$w_{i,t} = \frac{\dfrac{1}{\hat{\sigma}_{i,t}}}{\displaystyle\sum_{j \in S_t} \frac{1}{\hat{\sigma}_{j,t}}}. \tag{6}$$

A carteira permanece integralmente investida, sem alavancagem nem posições vendidas. Cada regra de seleção é avaliada também com pesos iguais, $w_{i,t} = 1/\,|S_t|$, de modo que as duas versões compartilham os mesmos ativos em cada data e diferem apenas na ponderação. Essa construção permite atribuir as diferenças nos indicadores exclusivamente ao esquema de dimensionamento.

IV. Especificações da aplicação

A. Calendário de rebalanceamento e execução

O sinal é calculado com preços de fechamento do último pregão de cada mês. Como esse preço só é conhecido após o encerramento do pregão, a ordem é executada no fechamento do pregão seguinte, e a nova composição passa a afetar os retornos a partir do dia posterior. A defasagem evita o uso de informação indisponível no momento da decisão, fonte clássica de *forward bias* em backtests que executam no mesmo preço usado para gerar o sinal. Entre rebalanceamentos, os pesos evoluem com os retornos dos ativos, como em uma carteira real não rebalanceada, e voltam aos pesos-alvo na execução seguinte. O backtest se inicia em janeiro de 2017, com a primeira ordem executada em 1º de fevereiro de 2017.

A ausência de vazamento de informação na implementação foi verificada empiricamente: substituindo todos os preços posteriores a uma data de corte por valores artificiais, os sinais, as volatilidades previstas e os retornos da estratégia até essa data permanecem inalterados.

B. Custos de transação e retorno líquido

O *turnover* de cada data de execução é a soma das variações absolutas entre os pesos-alvo e os pesos vigentes imediatamente antes da ordem,

$$\tau_t = \sum_i \left| w_{i,t}^{\text{alvo}} - w_{i,t}^{\text{vigente}} \right|, \tag{7}$$

sem divisão por dois, de modo que compras e vendas são contabilizadas, e a entrada inicial também gera custo. O retorno líquido é

$$r_{\text{líq}}(t) = (1 + r_{\text{bruto}}(t)) \cdot (1 - c \cdot \tau_t) - 1, \tag{8}$$

com custo-base $c = 0{,}10\%$ sobre o valor negociado e análise de sensibilidade com $c = 0\%$ e $c = 0{,}30\%$. A ponderação por volatilidade tende a elevar o *turnover* em relação aos pesos iguais, pois os pesos se alteram a cada mês mesmo quando a composição da carteira se mantém, e a modelagem de custos captura esse efeito.

C. Divisão amostral e seleção da configuração

A amostra é dividida em quatro períodos, resumidos na Tabela I. O treino inclui deliberadamente o choque de 2020, de modo que a configuração escolhida seja exposta também a um período de estresse. As posições e a memória do *deadband* são preservadas na passagem entre períodos, sem nova entrada artificial. O teste termina em 30/12/2025, última data em que todas as referências estão disponíveis; os preços de 2026 não são utilizados.

TABELA I
Divisão amostral

Período	Finalidade
2015–2016	Histórico inicial: forma os primeiros sinais e estima os primeiros modelos; nenhuma operação
2017–2020	Treino: as 150 configurações são comparadas e a final é escolhida
2021	Validação: verifica a configuração escolhida fora do período de escolha
2022–2025	Teste: executado uma única vez, com todos os parâmetros congelados

A grade avaliada combina três janelas de momentum, cinco regras de seleção e dez esquemas de ponderação (pesos iguais; GARCH e GJR com três janelas cada; EWMA com três fatores de decaimento), totalizando 150 configurações. A configuração final é a de maior Sharpe no treino. Esse procedimento exige disciplina: ao escolher entre muitas alternativas, a configuração vencedora tende a carregar parte de acaso específico da amostra, e só a validação e o teste permitem distinguir desempenho persistente de ajuste ao período. Além da configuração escolhida, o teste reporta o par central do estudo, o momentum 12-1 Top 5 com pesos iguais e com pesos por volatilidade, e a grade completa como evidência de robustez. Nenhuma dessas configurações foi alterada após a observação do teste.

D. Métricas de avaliação

As estratégias são avaliadas pelo retorno anual composto, pela volatilidade anualizada (desvio-padrão diário multiplicado por $\sqrt{252}$), pelo máximo *drawdown*, medido em relação ao maior patrimônio anterior e incluindo o patrimônio inicial, e pelo *turnover* anual. A métrica principal é o índice de Sharpe sobre o excesso de retorno em relação ao CDI:

$$\text{Sharpe} = \frac{\text{média}(r_t - \text{cdi}_t)}{\text{desvio-padrão}(r_t - \text{cdi}_t)} \cdot \sqrt{252}. \tag{9}$$

Todas as medidas de Sharpe são calculadas sobre o CDI, o que garante comparabilidade entre configurações e entre períodos.

Três medidas complementam a avaliação. A significância das diferenças de Sharpe entre duas estratégias é avaliada por *bootstrap* estacionário pareado dos retornos diários em excesso ao CDI, com blocos de tamanho médio de 21 pregões e 5.000 reamostragens; os blocos preservam a dependência serial e a reamostragem conjunta preserva a correlação entre as estratégias. A exposição ao mercado é medida pela regressão

$$r_t - \text{cdi}_t = a + b \cdot \left(r_t^{\text{IBOV}} - \text{cdi}_t \right) + \varepsilon_t, \tag{10}$$

com erros-padrão robustos a heterocedasticidade e autocorrelação (5 defasagens) e alfa anualizado por $252 \cdot a$. Por fim, a qualidade das previsões de volatilidade é medida pela função de perda QLIKE,

$$\text{QLIKE}_{i,t} = \frac{\text{RV}_{i,t}}{\hat{\sigma}_{i,t}^2} - \ln\left(\frac{\text{RV}_{i,t}}{\hat{\sigma}_{i,t}^2} \right) - 1, \tag{11}$$

em que $\text{RV}_{i,t}$ é a média dos log-retornos ao quadrado nos 21 pregões seguintes à data do sinal. A perda é nula quando a previsão acerta, penaliza mais a subestimação do risco do

TABELA IV
DESEMPENHO DAS ESTRATÉGIAS E DAS REFERÊNCIAS

	Treino (2017–2020)				Validação (2021)				Teste (2022–2025)			
Estratégia	Ret.	Vol.	Sharpe	MDD	Ret.	Vol.	Sharpe	MDD	Ret.	Vol.	Sharpe	MDD
6-1 Top 5, iguais (escolhida)	64,2	36,6	**1,378**	−56,7	35,3	32,4	**0,962**	−18,1	0,5	21,4	−0,427	−40,6
12-1 Top 5, iguais	49,0	36,4	1,115	−51,3	24,7	33,6	0,695	−23,0	12,9	20,7	**0,111**	−23,0
12-1 Top 5, GARCH(1,1)	37,6	34,1	0,933	−46,8	22,2	33,2	0,639	−23,7	12,0	19,7	0,067	−24,0
12-1 Top 5, GJR	38,2	33,9	0,950	−45,9	22,2	33,2	0,639	−23,8	11,6	19,7	0,048	−24,5
12-1 Top 5, EWMA	42,2	34,5	1,021	−47,9	20,0	32,9	0,587	−23,8	12,9	19,6	0,109	−23,4
Carteira igual (30 ativos)	31,1	28,0	0,894	−47,1	1,2	21,2	−0,040	−18,5	9,5	18,2	−0,066	−20,2
Ibovespa	19,0	28,2	0,544	−46,8	−12,2	21,0	−0,718	−22,9	11,5	16,8	0,019	−20,9
IBrX 50	18,5	28,7	0,525	−47,7	−10,7	21,5	−0,623	−23,4	–	–	–	–
Small Cap	26,8	28,7	0,764	−51,7	−16,5	25,5	−0,747	−31,3	–	–	–	–
Dividendos	20,7	25,4	0,629	−40,9	−6,5	19,1	−0,486	−16,0	–	–	–	–
CDI	6,3	0,2	–	0,0	4,4	0,1	–	0,0	12,7	0,1	–	0,0

que a superestimação e é comparada com uma referência ingênua, o desvio-padrão histórico dos últimos 252 pregões.

E. Implementação

A implementação está organizada em módulos complementares. O primeiro reúne as regras comuns a todas as variantes: preparação da base, seleção por Top N e *deadband*, backtest com pesos que evoluem entre rebalanceamentos, custos e métricas. O segundo acrescenta a leitura da base, a obtenção do CDI, a estimação dos modelos de volatilidade nas datas de sinal e a ponderação pelo inverso da volatilidade prevista. Sobre eles são executadas a grade de configurações, a comparação com as referências e os testes de heterocedasticidade da Seção III.B. Como todas as etapas compartilham o mesmo conjunto de funções, as variantes diferem apenas no componente de interesse. Os trechos centrais do código estão no Apêndice B.

V. RESULTADOS

A. Treino: a grade e a escolha da configuração

No treino, todas as 150 configurações têm Sharpe positivo sobre o CDI, com mediana de 0,91. A Tabela II resume as 15 combinações de janela e seleção com pesos iguais. Duas regularidades aparecem: carteiras mais concentradas (Top 5) e janelas mais curtas (6-1) dominam, e o *deadband* reduz o *turnover* sem compensar a perda de retorno. Pela regra estabelecida, a configuração final é o momentum 6-1 Top 5 com pesos iguais, com Sharpe de 1,378.

TABELA II
SHARPE SOBRE O CDI DAS COMBINAÇÕES COM PESOS IGUAIS

Janela	Seleção	Treino	Valid.	Teste	Turn.
6-1	Top 5	**1,378**	0,962	−0,427	9,1
6-1	Top 10	1,032	0,600	−0,425	6,9
6-1	Top 15	0,948	0,377	−0,230	5,4
6-1	Deadband 7	1,265	0,784	−0,385	7,5
6-1	Deadband 10	1,228	0,741	−0,442	5,6
9-1	Top 5	1,022	1,041	−0,446	6,7
9-1	Top 10	0,843	0,425	−0,061	6,0
9-1	Top 15	0,991	−0,031	−0,087	4,4
9-1	Deadband 7	1,051	0,937	−0,260	4,9
9-1	Deadband 10	0,905	0,475	−0,047	3,9
12-1	Top 5	1,115	0,695	0,111	6,0
12-1	Top 10	0,958	0,408	−0,425	4,7
12-1	Top 15	1,027	0,309	−0,194	3,8
12-1	Deadband 7	0,978	0,218	0,210	4,7
12-1	Deadband 10	0,870	−0,062	0,404	3,6

Custo de 0,10% sobre o valor negociado. *Turnover* anual no treino. Em negrito, a configuração escolhida pelo maior Sharpe no treino.

A Tabela III mostra a melhor configuração de cada família de ponderação no treino. As quatro escolhem a mesma seleção (6-1 Top 5), o que confirma que a camada de seleção domina o resultado; entre os esquemas de ponderação, os pesos iguais vencem, seguidos pelo EWMA. Na validação, as quatro preservam Sharpe próximo de 0,9.

TABELA III
MELHOR CONFIGURAÇÃO DE CADA FAMÍLIA NO TREINO

Família	Configuração	Treino	Valid.	Teste
Pesos iguais	6-1 Top 5	1,378	0,962	−0,427
EWMA	6-1 Top 5, $\lambda = 0{,}97$	1,305	0,892	−0,598
GJR	6-1 Top 5, $w = 504$	1,258	0,911	−0,623
GARCH	6-1 Top 5, $w = 756$	1,255	0,940	−0,624

B. Desempenho no treino, na validação e no teste

A Tabela IV reporta os indicadores das estratégias centrais e das referências nos três períodos, e a Fig. 1 mostra a evolução do patrimônio. No treino, as estratégias de momentum superam todas as referências por margem ampla: a configuração escolhida rende 64,2% ao ano, contra 31,1% da carteira igual do universo e 19,0% do Ibovespa, com alfa anualizado de 34,3% em relação ao índice (estatística t de 2,96). A validação preserva esse quadro em um ano adverso para a bolsa: o Ibovespa cai 12,2%, a carteira igual praticamente empata com o CDI, e o momentum 6-1 Top 5 rende 35,3%, com Sharpe de 0,962.

O teste altera a conclusão. A configuração escolhida rende 0,5% ao ano entre 2022 e 2025, abaixo dos 12,7% do CDI, com Sharpe de −0,427 e *drawdown* de 40,6%; seu alfa passa a −9,5% ao ano, sem significância. Entre as 150 configurações, ela ocupa a 106ª posição no teste. O momentum 12-1 Top 5 resiste melhor: suas quatro versões têm Sharpe ligeiramente positivo, entre 0,048 e 0,111, e a versão com pesos iguais rende 12,9% ao ano, praticamente o mesmo que o CDI (12,7%) e pouco acima do Ibovespa (11,5%). Nove anos depois, as duas configurações de pesos iguais chegam ao mesmo patrimônio final, cerca de 9,6 vezes o capital inicial, por caminhos opostos: a 6-1 acumulou quase todo o ganho até 2021, e a 12-1 continuou crescendo no teste.

A deterioração não é específica da configuração escolhida. A Fig. 2 relaciona o Sharpe de cada configuração no treino e no teste. Apenas 30 das 150 configurações superam o CDI no teste, e a correlação de postos entre o Sharpe no treino e no

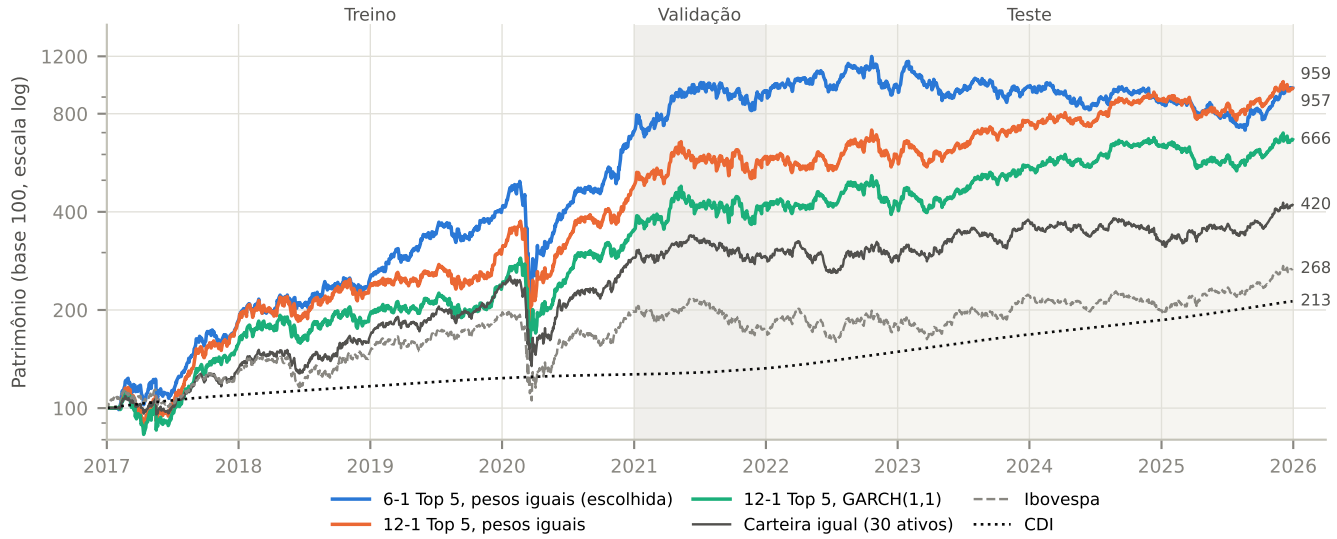


Fig. 1. Patrimônio acumulado, líquido de custos, das estratégias centrais e das referências (base 100 em janeiro de 2017, escala logarítmica). As áreas sombreadas marcam a validação e o teste; os números à direita são o patrimônio final em dezembro de 2025.

teste é de −0,53; entre validação e teste, de −0,74. As configurações mais bem avaliadas dentro da amostra, concentradas na janela 6-1, estão entre as piores fora dela, enquanto as melhores no teste usam a janela 12-1 com *deadband* 10, que tinham Sharpe modesto no treino. O resultado é o padrão típico de seleção sobre uma amostra curta e dominada por poucos episódios: a regra de escolha premiou a combinação que melhor se ajustou ao ciclo de 2017 a 2021, e não uma propriedade persistente da estratégia.

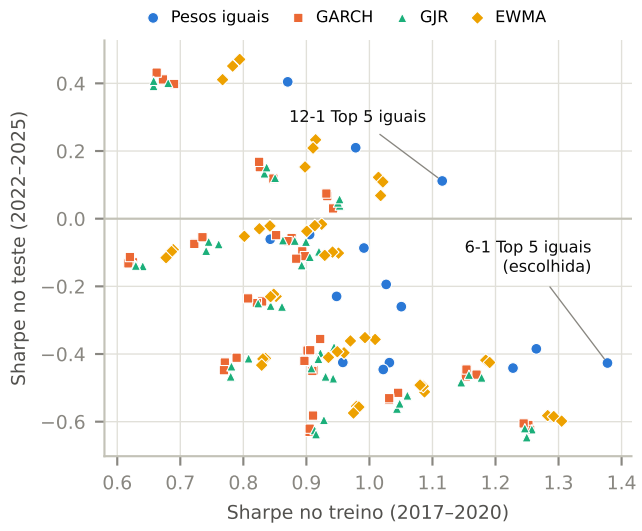


Fig. 2. Sharpe no treino e no teste das 150 configurações, por esquema de ponderação. A correlação de postos é de −0,53.

A Tabela V decompõe o resultado por ano. O teste combina dois anos de desempenho próximo de zero ou negativo para a configuração escolhida (2023 e 2024) com anos em que a carteira igual do universo e o Ibovespa avançaram fortemente (2023 e 2025). O momentum 12-1 Top 5 atravessou 2024 com ganho de 15,6%, quando o Ibovespa caiu 10,4%, mas ficou atrás do índice em 2025.

TABELA V
RETORNOS ANUAIS LÍQUIDOS DE CUSTOS (%)

Ano	6-1 T5 iguais	12-1 T5 iguais	12-1 T5 GARCH	Igual 30	IBOV	CDI
2017	82,1	80,7	54,7	30,4	26,9	9,8
2018	33,9	28,3	22,7	24,8	15,0	6,3
2019	63,3	27,9	21,9	44,3	31,6	5,9
2020	75,7	60,9	51,1	23,1	2,9	2,7
2021	34,5	24,1	21,7	1,2	−11,9	4,3
2022	3,9	1,0	0,8	0,4	4,7	12,3
2023	−0,6	27,4	29,5	28,9	22,3	13,0
2024	−11,0	15,6	14,9	−14,2	−10,4	10,8
2025	10,9	8,6	4,5	29,2	34,0	14,2

6-1 T5 é a configuração escolhida (pesos iguais); 12-1 T5 usa pesos iguais e 12-1 GARCH usa pesos pelo inverso da volatilidade prevista pelo GARCH(1,1) com janela de 756 pregões. Os anos de 2017 e 2025 não são completos: o primeiro começa sem posição até a execução de 1º de fevereiro e o segundo termina em 30/12/2025.

A comparação com a carteira igual do universo é a mais exigente, porque ela compartilha o mesmo universo, as mesmas datas e os mesmos custos. No treino, a configuração escolhida supera essa carteira com diferença de Sharpe de 0,48, estatisticamente significativa ao nível de 5% (Tabela VII). No teste, a diferença passa a −0,36 e deixa de ser significativa. Para o momentum 12-1 Top 5, a vantagem sobre a carteira igual é positiva nos dois períodos (0,22 e 0,18), mas em nenhum deles se distingue de zero. Com quatro anos de teste, o intervalo de confiança da diferença de Sharpe tem amplitude de 1,6 a 1,7, o que limita o que se pode afirmar sobre a camada de seleção.

C. *Efeito do dimensionamento por volatilidade*

A comparação entre esquemas de ponderação com a mesma seleção é o teste mais limpo da camada de dimensionamento. A Fig. 3 mostra a diferença de Sharpe entre os pesos por volatilidade e os pesos iguais para as 135 combinações, e a Tabela VI resume as medianas. No treino, a

ponderação por volatilidade reduz o Sharpe em todas as 135 combinações, com perda mediana de 0,143 para o GARCH, 0,131 para o GJR e 0,085 para o EWMA. A perda diminui na validação e quase desaparece no teste, em que 28% das combinações passam a ser favorecidas pela ponderação, e 44% no caso do EWMA.

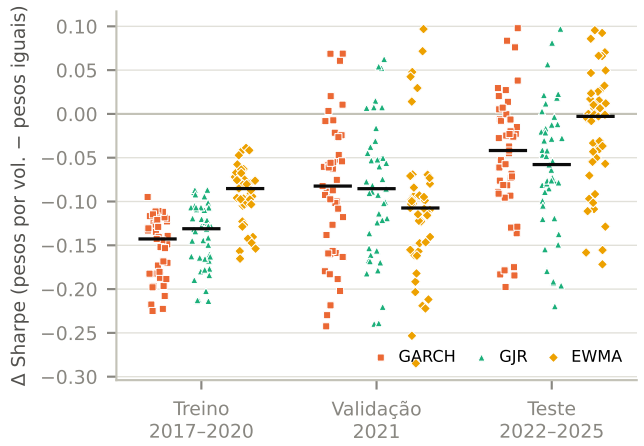


Fig. 3. Diferença de Sharpe entre pesos por volatilidade e pesos iguais, mantida a mesma seleção, para as 45 combinações de cada família. Os traços pretos marcam as medianas.

TABELA VI
Efeito mediano da ponderação por volatilidade

Medida	Família	Treino	Valid.	Teste
Δ Sharpe	GARCH	−0,143	−0,082	−0,042
	GJR	−0,131	−0,085	−0,058
	EWMA	−0,085	−0,107	−0,003
Combinações com Δ > 0	Todas	0%	15%	28%
Δ Volatilidade (p.p.)	GARCH	−2,3	−1,5	−1,1
	GJR	−2,5	−1,3	−1,1
	EWMA	−1,8	−1,6	−1,2
Δ *Drawdown* (p.p.)	GARCH	+3,7	+0,2	−0,2
	GJR	+4,1	+0,3	−0,6
	EWMA	+3,2	+0,1	+0,1

Diferenças entre a versão ponderada por volatilidade e a versão com pesos iguais da mesma combinação de janela e seleção; medianas sobre as 45 combinações de cada família. Δ *Drawdown* positivo indica queda máxima menor.

O lado do risco funciona como esperado. A volatilidade realizada cai em todos os períodos, entre 1,1 e 2,5 pontos percentuais na mediana, e o *drawdown* máximo do treino, concentrado na queda de março de 2020, é de 3 a 4 pontos menor. O problema está no retorno: no treino, a ponderação retira em mediana cerca de 9 pontos percentuais de retorno anual nas famílias GARCH e GJR, perda muito maior do que o ganho proporcional de risco. Os custos agravam o quadro, porque a ponderação eleva o *turnover* anual do momentum 12-1 Top 5 de 6,0 para 7,0 no treino e de 7,2 para 8,5 no teste, já que os pesos mudam a cada mês mesmo quando a composição se mantém.

Para o par central do estudo, o momentum 12-1 Top 5, a Tabela VII mostra que a perda de Sharpe com o GARCH(1,1) é estatisticamente significativa no treino (−0,182, com $p = 0{,}034$) e na amostra completa de 2017 a 2025 (−0,120, com $p = 0{,}021$). O GJR tem perda semelhante e significativa na amostra completa; o EWMA, mais suave, não se distingue dos pesos iguais em nenhum período. No teste, nenhuma das três diferenças é significativa.

TABELA VII
Diferenças de Sharpe por bootstrap estacionário

Comparação e período	Δ Sharpe	IC 95%	p
6-1 Top 5 iguais (escolhida) − carteira igual			
Treino	0,484	[0,01; 1,05]	0,044
Teste	−0,361	[−1,14; 0,43]	0,392
12-1 Top 5 iguais − carteira igual			
Treino	0,221	[−0,35; 0,68]	0,432
Teste	0,177	[−0,64; 1,04]	0,681
12-1 Top 5: GARCH(1,1) − pesos iguais			
Treino	−0,182	[−0,41; −0,01]	0,034
Teste	−0,045	[−0,23; 0,14]	0,640
2017–2025	−0,120	[−0,24; −0,02]	0,021
12-1 Top 5: GJR − pesos iguais			
Treino	−0,165	[−0,40; 0,01]	0,069
Teste	−0,064	[−0,23; 0,11]	0,470
2017–2025	−0,118	[−0,24; −0,01]	0,040
12-1 Top 5: EWMA − pesos iguais			
Treino	−0,094	[−0,26; 0,06]	0,200
Teste	−0,003	[−0,19; 0,20]	0,992

Bootstrap estacionário pareado dos retornos diários líquidos em excesso ao CDI, com blocos de tamanho médio de 21 pregões e 5.000 reamostragens. GARCH e GJR com janela de 756 pregões; EWMA com $\lambda = 0{,}94$. Intervalos de confiança por percentis.

D. O mecanismo: momentum e volatilidade prevista

A perda causada pela ponderação tem uma explicação direta. Nas datas de sinal do treino, a volatilidade anual prevista pelo GARCH(1,1) para os ativos do momentum 12-1 Top 5 é, em média, de 53,9%, contra 41,6% para o universo. Os vencedores do período, MGLU3 (presente em 46 dos 48 meses do treino) e PRIO3 (39 meses), eram também os ativos mais voláteis da carteira. Ponderar pelo inverso do risco significa, nesse contexto, reduzir sistematicamente a exposição aos ativos que sustentavam o retorno: em média, entre 2017 e 2025, o ativo mais volátil da carteira recebe 13,5% do capital e o menos volátil, 28,0%, contra 20% de cada um com pesos iguais.

A Fig. 4 mostra que essa relação não é estável. A correlação de postos entre o sinal de momentum e a volatilidade prevista é positiva em quase todo o treino, com média de 0,20, e de 0,27 na validação, mas torna-se negativa no teste, com média de −0,26. Entre 2022 e 2025, os ativos líderes do momentum passaram a ser papéis de volatilidade moderada, como PETR4, EMBJ3, BBAS3, CMIG4 e ITUB4, e a volatilidade prevista dos selecionados (34,9%) ficou praticamente igual à do universo (34,1%). Sem a associação entre vencedores e risco, o inverso da volatilidade deixa de penalizar a carteira, o que explica por que a perda de Sharpe encolhe no teste. A ponderação por volatilidade, portanto, não é neutra em relação ao sinal: seu custo depende de quanto o momentum, em cada fase do mercado, está concentrado em ativos arriscados.

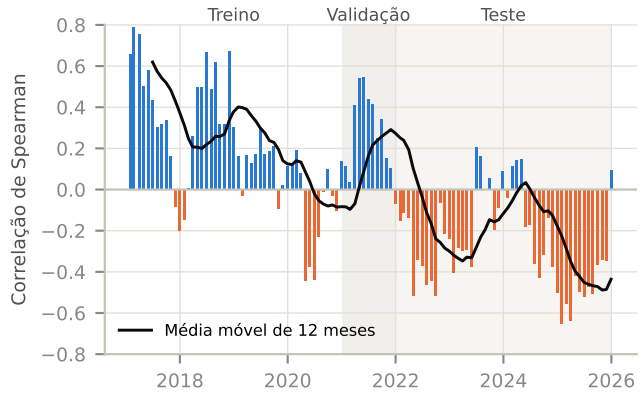


Fig. 4. Correlação de postos de Spearman, em cada data de sinal, entre o momentum 12-1 e a volatilidade prevista pelo GARCH(1,1) para os ativos do universo.

E. Qualidade das previsões de volatilidade

A Tabela VIII avalia as previsões diretamente. No treino, todos os modelos condicionais têm perda QLIKE menor do que a referência histórica, com destaque para o GJR com janela de 504 pregões, embora sem significância estatística no teste de igualdade de perdas, e na validação o GARCH e o GJR com janelas longas também superam a referência, com estatísticas t próximas de -2. No teste, a vantagem desaparece: a volatilidade histórica de 252 pregões tem a menor perda, e o EWMA com decaimento rápido é significativamente pior. A previsão de volatilidade, portanto, é informativa, mas não uniformemente melhor do que uma medida simples; e, como mostram as seções anteriores, mesmo previsões mais precisas não se traduzem em Sharpe maior quando o risco previsto está associado ao retorno esperado.

TABELA VIII
PERDA QLIKE MÉDIA DAS PREVISÕES DE VOLATILIDADE

Modelo	Treino	Valid.	Teste
GARCH, $w = 504$	0,410	0,183	0,187
GARCH, $w = 756$	0,427	0,165	0,186
GARCH, $w = 1008$	0,424	0,163	0,194
GJR, $w = 504$	**0,381**	0,186	0,186
GJR, $w = 756$	0,401	0,164	0,185
GJR, $w = 1008$	0,411	0,160	0,194
EWMA, $\lambda = 0{,}90$	0,406	0,218	0,264
EWMA, $\lambda = 0{,}94$	0,409	0,180	0,221
EWMA, $\lambda = 0{,}97$	0,455	**0,159**	0,188
Histórica, 252 pregões	0,597	0,216	**0,182**

Média sobre ativos e datas de sinal; menor é melhor. Em negrito, a menor perda de cada período.

F. Robustez

A Tabela IX avalia a sensibilidade das três estratégias centrais a custos, à data de execução e à composição do universo. A ordenação entre pesos iguais e GARCH no momentum 12-1 Top 5 se mantém em todas as variantes do treino. A exclusão das classes duplicadas (KLBN3 e SANB3) melhora levemente os resultados, sem alterar conclusões. A variante mais reveladora é a exclusão da MGLU3: o Sharpe do momentum 12-1 Top 5 no treino cai de 1,115 para 0,580, abaixo dos 0,788 da carteira igual do universo também sem a MGLU3. A vantagem do momentum dentro da amostra depende, portanto, de um único ativo que se valorizou mais de cem vezes no período, o que reforça a interpretação dos resultados de treino como específicos daquele ciclo.

TABELA IX
SHARPE SOBRE O CDI SOB VARIAÇÕES DA ESPECIFICAÇÃO

Variante	6-1 T5	12-1 T5	12-1 GARCH
Treino (2017–2020)			
Base (custo de 0,10%)	1,378	1,115	0,933
Custo de 0%	1,402	1,132	0,954
Custo de 0,30%	1,328	1,082	0,892
Execução em $t + 2$	1,425	1,128	0,959
Sem KLBN3 e SANB3	1,448	1,113	0,928
Sem MGLU3	0,986	0,580	0,470
Teste (2022–2025)			
Base (custo de 0,10%)	−0,427	0,111	0,067
Custo de 0%	−0,378	0,146	0,110
Custo de 0,30%	−0,524	0,041	−0,020
Execução em $t + 2$	−0,437	0,088	0,039
Sem KLBN3 e SANB3	−0,312	0,162	0,126
Sem MGLU3	−0,595	0,099	0,037

VI. DISCUSSÃO CRÍTICA E LIMITAÇÕES

O desenho amostral cumpriu sua função: sem a separação entre treino, validação e teste, o trabalho reportaria uma estratégia com Sharpe de 1,38 e alfa significativo, quando o desempenho fora da amostra foi inferior ao do CDI. Essa diferença é a principal lição metodológica do estudo e tem três origens que se reforçam.

Primeiro, a escolha entre 150 configurações em quatro anos de dados favorece o ajuste ao período. O erro-padrão de um Sharpe estimado em quatro anos é da ordem de 0,6, maior do que a distância entre as melhores configurações da grade, de modo que a ordenação no treino reflete em boa parte acaso amostral. A correlação negativa entre as ordenações do treino e do teste mostra que, nesta amostra, o critério de escolha não apenas falhou em identificar a melhor configuração, como selecionou contra ela. A validação de um único ano não foi suficiente para detectar o problema, porque 2021 ainda pertenceu ao mesmo ciclo de alta dos vencedores.

Segundo, o universo foi definido com informação atual. A dependência dos resultados de treino em relação à MGLU3 e à PRIO3 é a expressão concreta desse viés: empresas que se tornaram grandes ao longo do período estão na amostra justamente por terem se tornado grandes. Um universo reconstruído data a data, com os ativos líquidos de cada momento, provavelmente reduziria o desempenho dentro da amostra.

Terceiro, o comportamento do momentum depende do regime. O período de treino combinou forte dispersão entre ações e liderança persistente de poucos papéis, condição favorável ao sinal; o teste, marcado por juros altos e rotação setorial, foi desfavorável. O mesmo vale para o dimensionamento: a correlação entre vencedores e volatilidade, que tornou a ponderação custosa no treino, inverteu-se no teste.

Há ainda limitações de construção. O CDI de 2022 a 2025 foi reconstruído a partir da Selic efetiva por período de vigência, procedimento validado contra a série oficial no

período de sobreposição, mas que pode diferir ligeiramente dela. As janelas longas de estimação só estão completas a partir de 2018 e 2019. Os custos de 0,10% sobre o valor negociado não incluem impacto de mercado, que seria relevante para carteiras concentradas em cinco ativos. Por fim, os testes de significância não corrigem a multiplicidade de comparações da grade, o que tornaria as conclusões favoráveis ao momentum ainda mais frágeis.

VII. Conclusão

Este trabalho construiu uma estratégia de duas camadas para o mercado acionário brasileiro, com seleção por momentum de seção transversal e dimensionamento por volatilidade prevista por modelos GARCH, e a avaliou sob um protocolo que separa escolha, validação e teste.

Os resultados respondem às duas perguntas do estudo de forma distinta. Sobre a seleção, o momentum gerou retornos muito superiores às referências entre 2017 e 2021, mas a configuração escolhida pelo maior Sharpe no treino teve desempenho inferior ao do CDI entre 2022 e 2025, e a ordenação das configurações se inverteu fora da amostra. Apenas o momentum 12-1 Top 5, a especificação mais próxima da convencional, manteve Sharpe ligeiramente positivo no teste, com retorno em linha com o CDI e próximo ao do Ibovespa. Sobre o dimensionamento, a ponderação pelo inverso da volatilidade prevista reduziu o risco realizado em todos os períodos, mas não melhorou o retorno ajustado ao risco: no treino, piorou o Sharpe em todas as combinações, de forma estatisticamente significativa para o GARCH(1,1), e no teste seu efeito foi próximo de zero.

A contribuição mais útil do estudo é a identificação do mecanismo. A ponderação por volatilidade só é neutra em relação ao retorno quando o risco previsto não está associado ao sinal que seleciona os ativos. No momentum brasileiro do período, os vencedores eram os ativos mais arriscados, e reduzir o peso deles significou abrir mão do próprio retorno da estratégia. Quando essa associação desapareceu, o custo também desapareceu. Extensões naturais incluem escalar a exposição total da carteira pela volatilidade prevista, em vez de redistribuir pesos entre os ativos selecionados, reconstruir o universo investível data a data e avaliar a estratégia em janelas móveis de escolha, que reduzem a dependência de um único período de treino.

Apêndice A: universo de ativos

A Tabela X lista os 30 ativos do universo, com a empresa emissora, o setor, a data da primeira cotação disponível e a volatilidade anualizada. A amostra de preços cobre de 02/01/2015 a 21/10/2026, totalizando 2.930 pregões. A volatilidade é o desvio-padrão dos log-retornos diários entre 2015 e 2021, multiplicado por $\sqrt{252}$. KLBN3 e KLBN11, assim como SANB3 e SANB11, são classes de ações de um mesmo emissor. A CAML3 inicia sua série em setembro de 2017, data de sua listagem.

TABELA X
Universo de ativos

Empresa	Ticker	Setor	Início	Vol.
B3	B3SA3	Financeiro	02/01/2015	37,8
Banco do Brasil	BBAS3	Financeiro	02/01/2015	45,7
Bradesco	BBDC4	Financeiro	02/01/2015	36,8
Itaú Unibanco	ITUB4	Financeiro	02/01/2015	33,2
Multiplan	MULT3	Financeiro	02/01/2015	37,8
Santander (ON)	SANB3	Financeiro	02/01/2015	48,6
Santander (unit)	SANB11	Financeiro	02/01/2015	37,8
Braskem	BRKM5	Materiais básicos	02/01/2015	52,6
CSN	CSNA3	Materiais básicos	02/01/2015	63,7
Gerdau	GGBR4	Materiais básicos	02/01/2015	49,8
Klabin (ON)	KLBN3	Materiais básicos	16/01/2015	51,4
Klabin (unit)	KLBN11	Materiais básicos	02/01/2015	31,2
Metalúrgica Gerdau	GOAU4	Materiais básicos	02/01/2015	55,3
Usiminas	USIM5	Materiais básicos	02/01/2015	62,7
Vale	VALE3	Materiais básicos	02/01/2015	48,4
Petrobras	PETR4	Petróleo e gás	02/01/2015	53,0
PRIO	PRIO3	Petróleo e gás	02/01/2015	77,3
Cemig	CMIG4	Utilidade pública	02/01/2015	46,0
Engie Brasil	EGIE3	Utilidade pública	02/01/2015	24,8
Equatorial	EQTL3	Utilidade pública	02/01/2015	28,2
Taesa	TAEE11	Utilidade pública	02/01/2015	24,5
Cyrela	CYRE3	Consumo cíclico	02/01/2015	46,7
Localiza	RENT3	Consumo cíclico	02/01/2015	43,8
Magazine Luiza	MGLU3	Consumo cíclico	02/01/2015	64,2
MRV Engenharia	MRVE3	Consumo cíclico	02/01/2015	41,4
Ambev	ABEV3	Consumo não cíclico	02/01/2015	27,9
Camil	CAML3	Consumo não cíclico	27/09/2017	32,8
Embraer	EMBJ3	Bens industriais	02/01/2015	46,5
WEG	WEGE3	Bens industriais	02/01/2015	35,1
Raia Drogasil	RADL3	Saúde	02/01/2015	31,5

Fonte: Economatica. Preços de fechamento ajustados por proventos, em moeda original. Vol.: volatilidade anualizada de 2015 a 2021, em %.

Apêndice B: código

Este apêndice reproduz os trechos centrais da implementação, associados às equações do texto. As verificações de consistência das entradas foram omitidas por espaço, e algumas linhas foram quebradas para caber na coluna; a lógica é a mesma do repositório do projeto.

B.1 Sinal de momentum. Implementa a equação (2): o sinal é calculado em todos os pregões, e apenas o último pregão de cada mês é mantido como data de formação.

```
def calcular_momentum_mensal(precos, dias, skip=SKIP,
                             inicio_bt=INICIO_BACKTEST,
                             fim=FIM_DADOS):
    indicador = precos.shift(skip) / precos.shift(dias) - 1
    mensal = indicador.groupby(
        indicador.index.to_period("M")).tail(1)
    return mensal.loc[inicio_bt:fim]
```

B.2 Seleção Top N e deadband. Regras da seleção da carteira. No *deadband*, os ativos já presentes são mantidos enquanto permanecem entre as primeiras posições do ranking definidas pelo limite.

```
def criar_top_n(momentum_mensal, n):
    historico = {}
    for data, linha in momentum_mensal.iterrows():
        ranking = linha.dropna().sort_values(
            ascending=False, kind="stable")
        if len(ranking) >= n:
            historico[data] = ranking.head(n).index.tolist()
    return pd.DataFrame.from_dict(
        historico, orient="index",
        columns=[f"Ativo {i}" for i in range(1, n + 1)])

def criar_deadband(momentum_mensal, limite, n=5):
    carteira, historico = [], {}
    for data, linha in momentum_mensal.iterrows():
        ranking = linha.dropna().sort_values(
            ascending=False, kind="stable")
        if len(ranking) < n:
            continue
        permitidos = ranking.head(limite).index
```

```
        carteira = [a for a in carteira if a in permitidos]
        for ativo in ranking.index:
            if len(carteira) == n:
                break
            if ativo not in carteira:
                carteira.append(ativo)
        historico[data] = carteira.copy()
    return pd.DataFrame.from_dict(
        historico, orient="index",
        columns=[f"Ativo {i}" for i in range(1, n + 1)])
```

B.3 Previsão de volatilidade. Implementa as equações (3), (4) e (5): estimação com log-retornos em pontos percentuais, média zero e inovações t, e raiz da variância média prevista para os 21 pregões seguintes. Em caso de não convergência, a função retorna valor ausente e a previsão de reserva por EWMA é usada.

```
def garch_forecast(x, model, horizon, min_obs):
    x = x.dropna() * 100
    if len(x) < min_obs:
        return np.nan
    try:
        am = arch_model(x, mean="Zero", vol="GARCH", p=1,
                        o=1 if model == "gjr" else 0, q=1,
                        dist="t", rescale=False)
        res = am.fit(disp="off", show_warning=False)
        if res.convergence_flag != 0:
            return np.nan
        var_path = res.forecast(
            horizon=horizon, reindex=False).variance.values[-1]
        return float(np.sqrt(var_path.mean()) / 100)
    except Exception:
        return np.nan
```

B.4 Ponderação pelo inverso da volatilidade. Implementa a equação (6). Os ativos são os mesmos da seleção com pesos iguais; apenas os pesos mudam.

```
def criar_pesos_vol(carteira, sigma, universo):
    pesos = pd.DataFrame(0.0, index=carteira.index,
                         columns=universo)
    for data, linha in carteira.iterrows():
        ativos = linha.dropna().tolist()
        s = sigma.loc[data, ativos].astype(float)
        s = s.where(s > 0)
        if s.isna().any():
            s = s.fillna(s.median() if s.notna().any()
                         else 1.0)
        w = 1.0 / s
        pesos.loc[data, ativos] = (w / w.sum()).values
    return pesos
```

B.5 Backtest e custos. Implementa as equações (1), (7) e (8). A ordem gerada no último pregão do mês é executada no pregão seguinte, pelo deslocamento de um pregão em `ordens`; entre execuções, os pesos evoluem com os retornos.

```
def backtest(pesos_alvo, retornos, inicio, fim):
    r_periodo = retornos.loc[inicio:fim]
    ordens = pesos_alvo.reindex(r_periodo.index).shift(1)
    pesos_atuais = pd.Series(0.0, index=retornos.columns)
    historico = []
    for data, r in r_periodo.iterrows():
        r = r.fillna(0.0)
        retorno_dia = float((pesos_atuais * r).sum())
        pesos_atuais = (pesos_atuais * (1 + r)
                        / (1 + retorno_dia))
        turnover = 0.0
        if ordens.loc[data].notna().all():
            novos = ordens.loc[data]
            turnover = float((novos - pesos_atuais).abs().sum())
            pesos_atuais = novos.copy()
        historico.append({"Data": data,
                          "Retorno": retorno_dia,
                          "Turnover": turnover})
    return pd.DataFrame(historico).set_index("Data")

def aplicar_custos(resultado, custo):
    return ((1 + resultado["Retorno"])
            * (1 - custo * resultado["Turnover"]) - 1)
```